

Sinkhorn 传输矩阵与模型感知 OT：问题—方案—理论要点— 难点—尝试（工作笔记）

（与 ChatGPT 讨论整理；见文末说明）

2026 年 4 月 11 日

摘要

本文档概括本仓库相关研究方向：在流匹配 / 条件流匹配（CFM、OT-CFM）中如何获得或学习样本间耦合（transport plan），以及 Sinkhorn 归一化在注意力与 OT 输出中的不同角色。正文在原有「问题—方案—难点—尝试」之外，增补一节 Sinkhorn 与双随机理论要点（ u, v 与 P 的关系、何时 doubly stochastic、有限步迭代的近似性），以及一节可微配对层（梯度经 $X^* = PX$ 回传、低秩 score、Hungarian+STE、用网络近似 Sinkhorn 的可行边界）。实现与实验仍指向仓库内脚本。

1 想解决什么问题

- **OT-CFM 与配对质量。**在 batch 内用最优传输思想为源点与目标点配对，可改善独立配对下的路径方差；精确 minibatch OT（如 EMD）代价高或需外部求解器，且与端到端「可学习配对」的需求不完全一致。
- **可学习的传输计划（assignment layer）。**目标不一定是「最优运输解」本身，而是一个可训练配对层：网络产生得分 $S_\theta(x, y)$ （或等价结构），再变为满足边际的 P ，下游损失通过 $X^* = PX$ （或加权聚合）反传，使配对结构与任务对齐。
- **概念厘清：Sinkhorn 出现在不同位置。**同一数学工具既可用于 Sinkformer（用 Sinkhorn 替代 softmax，得到双随机 attention），也可用于 OT 型模块（对 $N \times N$ 的 x_0-x_1 亲和度矩阵做 Sinkhorn，直接输出 plan）。两者目标与 shape 约定不同（见 experiments/architecture_comparison.md）。

2 采用的方案（概要）

- **OTTransformer / 验证脚本。**对两批点集编码、自注意力建上下文，再构造跨集得分 S_{ij} ，最后 `log_sinkhorn` 得到边际为 $1/N$ 的 plan P （总质量为 1）。见 experiments/ot_transformer_verify.py 与架构对比文档。
- **Sinkformer 式 pairer + 2D CFM 对比实验。**experiments/ot_cfm_vs_sinkformer_2d.py：一侧为 OT-CFM（精确 minibatch 配对 + 标准 FM loss）；另一侧为可学习 plan（Sinkhorn）+ 可选 Hungarian 硬匹配与 straight-through（STE），并支持 `--soft-pair`、`--frozen-pairer`、共享或逐对时间 t 等消融。

- **Sinkformer 注意力实现。** `model/sinkformer.py`: 多头自注意力中将 softmax 换为对数域 Sinkhorn 迭代，使权重矩阵（每头）近似双随机；与「输出 OT plan」的模块在任务定义上不同。

3 Sinkhorn 里 u, v 如何得到传输矩阵；何时 doubly stochastic

3.1 公式：对角缩放夹核矩阵，而非外积 $uv^\top$

熵正则 OT 在约束 $P\mathbf{1} = a$ 、 $P^\top \mathbf{1} = b$ ($P \geq 0$) 下，最优性条件给出

$$P_{ij} = u_i K_{ij} v_j, \quad K_{ij} = \exp(-C_{ij}/\varepsilon),$$

即矩阵形式 $P = \text{Diag}(u) K \text{Diag}(v)$ 。

注意：这与秩一外积 $uv^\top$ 不是同一对象； u, v 由边际方程确定，几何意义是对正核 K 做交替行/列缩放 (Sinkhorn-Knopp)。

3.2 是否一定 doubly stochastic?

一般 OT: 只保证指定边缘 a, b ，即行和为 a_i 、列和为 b_j ，不等同于「每行每列和均为 1」的经典 doubly stochastic。

方阵 + 均匀边际：若 $P \in \mathbb{R}^{n \times n}$ 且 $a = b = \frac{1}{n}\mathbf{1}$ (总质量 1)，则 P 为均匀边际下的双随机；若要与「行和列和均为 1」的常用定义对齐，差一个整体因子 n (缩放约定与代码实现需一致)。

3.3 有限步迭代

理论极限下 (正性、可缩放等条件满足) Sinkhorn 收敛到满足边际的 P 。

有限步：实现中只做 K 次迭代时，边际通常仅为近似满足；许多工作 (如围绕 mHC 的讨论) 明确将「截断 Sinkhorn」视为近似投影到 Birkhoff 多面体，而非严格落在集合内。

3.4 「任意输入都输出双随机」的参数化 (概念层)

- **正矩阵 + Sinkhorn:** $M_{ij} = \exp(S_{ij}/\tau)$ (或任意正 M)，再行列归一化；极限下满足给定边际。实用、可微，但依赖迭代且有限步近似。
- **Birkhoff-von Neumann:** 双随机矩阵为置换矩阵的凸包；用单纯形权重组合置换可严格保证双随机，但全体置换维度随 $n!$ 增长，仅小 n 上朴素可行。
- **简单秩一** $P = ab^\top$: 若同时要求非负与 (均匀边际下) 双随机，正秩一情形会退化为接近均匀矩阵 $\frac{1}{n}\mathbf{1}\mathbf{1}^\top$ ，无法表达有区分度的匹配。若写 $X^* = ab^\top X$ ，其效果更接近低秩混合算子 (先全局混合再广播)，而非一般意义上的配对矩阵。

4 可微配对：梯度、低秩 score、STE 与「学习投影」

4.1 损失经 $X^* = PX$ 时的梯度链

若 $X^* = PX$, $P = \text{Sinkhorn}(S_\theta)$, 且损失 $\mathcal{L}$ 依赖 X^* , 则链式法则给出

$$\frac{\partial \mathcal{L}}{\partial P} = \frac{\partial \mathcal{L}}{\partial X^*} X^\top,$$

再经 Sinkhorn 层对 S 的雅可比回传至 θ 。

要点：前向若使用配对后的 P , 则不能把用于损失的 P 随意 `detach` 又指望梯度更新 score。

若对 Sinkhorn 做完全展开自动微分, 反向代价与步数线性相关; 文献中有**隐式微分**等做法, 减轻展开步数带来的数值与内存问题 (可作后续改进方向)。

4.2 版本 B: Hungarian 硬前向 + STE 软反向

常用构造: $P_{\text{soft}} = \text{Sinkhorn}(S/\tau)$, $P_{\text{hard}} = \text{Hungarian}(P_{\text{soft}})$,

$$\tilde{P} = P_{\text{hard}} - \text{sg}(P_{\text{soft}}) + P_{\text{soft}}.$$

前向用 $\tilde{P}$ (语义上接近硬配对), 反向梯度经 P_{soft} 流动。**梯度有偏**, 但工程上常能跑通; 可靠性依赖温度 τ 、Sinkhorn 步数及任务对离散配对的敏感度, 需用消融与边际误差监控验证, 而非假设无偏。

4.3 低秩 $S = AB^\top$ 能省什么、不能省什么

低秩参数化可减少参数量并施加「两侧 embedding 相似度」的归纳偏置。但 $K = \exp(S/\tau)$ 一般不再低秩, 标准 Sinkhorn 仍对完整 $n \times n$ 矩阵做行列归一化, 算力与显存主项往往仍在。若要真正降低 n^2 级代价, 需结构更强的做法 (如 slot 上小块 OT、 $AMB^\top$ 式两级结构、或专门低秩 coupling 算法), 而不只是把 S 写成 $AB^\top$ 。

4.4 用神经网络近似 Sinkhorn 再冻结?

思路：训练 g_ϕ 使 $g_\phi(S) \approx \text{Sinkhorn}(S)$, 再冻结 g_ϕ , 主任务只训产生 S 的网络。

风险：学到的是训练分布上的近似投影, 分布漂移、温度或维度变化会失效; 近似边际误差被固定, 主网络无法修正投影器本身。

更稳折中：将 g_ϕ 视为 **warm-start** / 预条件, 再接少量 (如 1–3) 步 Sinkhorn 校正, 在速度与边际近似之间折中; 这与 amortized OT / learned initializer 的常见用法一致。

5 主要难点

- **离散指派与梯度。** Hungarian 为离散; STE 或软 plan 在「前向语义」与「反传信号」之间折中, 且 STE 有偏。
- **Sinkhorn:** 近似边际与截断迭代。步数过少或 τ 极端时, 前向语义与「双随机/边际」承诺偏离; 展开反向时步数影响梯度质量与开销。
- **联合训练与非凸性。** pairer 与 flow 纠缠; `--frozen-pairer` 等用于归因。
- **边际与缩放约定。** attention 与 OT plan 的总质量、行和列和约定需与损失一致 (见 `architecture_comparison.md`)。

6 如何尝试解决（仓库中的对应做法）

- 对比基线：OT-CFM 精确配对 vs 学习 plan + Sinkhorn (`ot_cfm_vs_sinkformer_2d.py`)。
- 可微与硬指派：默认 Hungarian + STE; `--soft-pair` 纯软对照。
- 消融 `pairer`：`--frozen-pairer` 检验失败来自配对还是流网络。
- 架构澄清：Standard Transformer / Sinkformer / OTTransformer 对比表(`architecture_comparison.md`)。
- 实践优先级（与讨论一致）：先软 Sinkhorn（或现有 STE）跑通；若对步数/ τ /反传敏感，再试隐式微分或 warm-start + 少量校正；小 n 再考虑置换凸组合等 exact 参数化。

7 关于 ChatGPT 对话链接

对话标题涉及「Sinkhorn Transport Matrix」。公开分享页 chatgpt.com/share/69da56c9-96c8-83a4-ad19-80d975ce2e02 在未登录状态下无法抓取正文；第 3–4 节已按后续讨论（ u, v 与 P 、双随机条件、低秩与梯度、STE、学习投影器）并入本文档。若需与原文逐句对齐，可将对话导出为 `sumerize_latex/chatgpt_export.txt` 再增补。